

LieCFM: Lie-algebraic Compositional Flow Matching

조합 섭동 예측을 위한 Lie 대수 기반 조건부 Flow Matching

Method 섹션 초안 · ICLR 투고 형식 · 2026-08-11

3.1 문제 설정

유전자 발현 공간을 R^D 라 하고, 섭동 어휘를 $G = \{1, \dots, N\}$ 이라 하자. 하나의 실험 조건은 동시에 가해진 섭동의 **순서 없는 부분집합** $P \subseteq G$ 로 표현된다. 대조군은 $P = \emptyset$ 이다. 각 조건에서 우리가 관측하는 것은 세포 집합이며, 측정이 파괴적이므로 대조군 세포와 섭동 세포는 **짜지어져 있지 않다**.

대조군 $x_0 \sim \mu_0$ ($P = \emptyset$)

섭동군 $x_1 \sim \mu_1^{\wedge P}$ (조건 P)

(1)

관측 $\{x_0^i\}_{i=1..n_0}, \{x_1^j\}_{j=1..n_1^{\wedge P}}$ — 짝 정보 없음

학습에는 조건의 부분집합 $P_{\text{train}} \subset 2^G$ 만 주어진다. 목표는 **학습에서 관측되지 않은 조합** $P^* \notin P_{\text{train}}$ 에 대하여 조건부 분포 $\mu_1^{\wedge P^*}$ 를 예측하는 것이다. 본 논문은 $|P| \leq 2$ 인 경우를 다루되, 제안하는 정식화는 임의의 $|P|$ 로 확장된다 (3.5절 Proposition 6).

이 과제의 난이도는 두 겹이다. 첫째, 짝 정보가 없으므로 세포 단위 회귀가 불가능하다. 둘째, 조합 효과는 구성 섭동의 단순 합이 아니며, 그 이탈(epistasis)을 **한 번도 함께 관측되지 않은 쌍**에 대해 예측해야 한다.

3.2 예비: 조건부 Flow Matching

Flow Matching 은 소스 분포에서 타겟 분포로 가는 시간 의존 벡터장을 회귀로 학습한다. 커플링 $\pi(x_0, x_1)$ 이 주어지면 선형 보간 경로와 그 위의 목표 속도가 정해지고, 조건부 목적함수는 다음과 같다.

$$x_t = (1 - t)x_0 + tx_1, u(x_0, x_1) = x_1 - x_0, t \sim U[0,1]$$

(2)

$$L_{\text{FM}}(\theta) = E_{\{(x_0, x_1) \sim \pi, t\}} \|v_\theta(x_t, t, P) - (x_1 - x_0)\|^2$$

학습된 v_θ 로 ODE $dx/dt = v_\theta(x, t, P)$ 를 $t: 0 \rightarrow 1$ 로 적분하면 μ_0 의 표본이 $\mu_1^{\wedge P}$ 의 표본으로 옮겨진다. 커플링 π 를 독립 곱으로 두면 경로가 곱고 분산이 크므로, 미니배치 최적수송으로 π 를 정한다 (3.6.1절).

3.3 동기: 조합은 상태가 아니라 동역학에서 합성된다

기존 조건부 생성 모델은 조합을 **인코딩**한다. 섭동 토큰 집합을 set attention, DeepSets, 또는 multi-hot 벡터로 하나의 조건 벡터 $c(P)$ 로 압축한 뒤 네트워크에 주입한다. 이 설계에서 조합 구조는 인코더 내부에 있고, 상호작용은 네트워크가 데이터로부터 우연히 학습하는 대상이다. 그 결과 **함께 관측된 적 없는 쌍**의 상호작용을 외삽할 구조적 근거가 없다.

우리는 다른 층위에서 합성한다. Flow Matching 에서 각 섭동은 하나의 **벡터장**을 유도한다. 매끄러운 벡터장의 집합은 Lie 괄호 아래에서 Lie 대수를 이루며, 흐름의 합성은 Baker–Campbell–Hausdorff(BCH) 전개가 지배한다. 벡터장 X, Y 의 시간 s 흐름을 Φ_X^s 라 하면

$$\Phi_X^s \circ \Phi_Y^s = \Phi_Z^s, Z = X + Y + (s/2)[X, Y] + O(s^2)$$

(3)

이 식이 본 논문의 출발점이다.

관찰 (가법성 = 가환성). 두 섭동의 생성 벡터장이 가환이면($[X,Y] = 0$) 조합의 흐름은 정확히 가법적이다. 따라서 **가법성으로부터의 이탈, 즉 epistasis 는 비가환성이다.** 이는 비유가 아니라 등식이며, 상호작용 항을 자유 신경망 대신 **대수가 강제하는 형태로** 둘 수 있음을 뜻한다.

3.4 LieCFM

3.4.1 잠재 리프팅

동역학은 잠재 공간 R^d ($d = 128$) 에서 정의한다. 리프팅은 전체 유전자에 대한 주성분 사영으로 고정한다.

$$z = \varphi(x) = W(x - x_c) \in R^d, \psi(z) = W^T z + x_c, W W^T = I_d \quad (4)$$

여기서 x_c 는 전체 세포의 평균이다. φ 가 선형이므로 (i) 역변환이 정확하고 오토인코더 재구성 오차 바닥이 없으며, (ii) 조건 평균의 차이가 잠재로 그대로 옮겨진다. 조건 P 의 유전자공간 평균을 m_P 라 하면 $\varphi(m_P) - \varphi(m_\emptyset) = W(m_P - m_\emptyset)$ 이다. 학습 가능한 비선형 인코더는 부록에서 변형으로 다룬다.

3.4.2 섭동 생성원

정의 1 (섭동 생성원). 각 섭동 $a \in G$ 에 대하여 시간 의존 **affine** 벡터장을 그 생성원으로 둔다.

$$\begin{aligned} u_a(z, t) &= A_a(t) z + b_a(t), A_a(t) = U_a(t) V_a(t)^T \in R^{d \times d}, \text{rank} \leq r \\ [U_a(t), V_a(t), b_a(t)] &= f_\theta(e_a, \tau(t)) \text{ (하이퍼네트워크)} \\ e_a &\in R^{d_e} \text{ 섭동 임베딩, } \tau(t) \text{ Fourier 시간 특징} \end{aligned} \quad (5)$$

생성원을 affine 으로 제한하는 것은 표현력의 임의적 축소가 아니라 데이터에 근거한 선택이다 (3.9절). 저랭크 인수분해 $A = U V^T$ 는 조건당 $O(d r)$ 파라미터만 쓰며, 뒤에서 보듯 **A** 를 명시적으로 구성하지 않고도 필요한 모든 연산을 수행할 수 있다.

3.4.3 Lie 괄호 상호작용

R^d 위의 매끄러운 벡터장 u, w 에 대한 Lie 괄호는 다음과 같다.

$$[u, w](z) = (\partial w / \partial z)(z) \cdot u(z) - (\partial u / \partial z)(z) \cdot w(z) \quad (6)$$

정의 1 의 affine 생성원에 이를 적용하면 닫힌 형태를 얻는다.

$$\begin{aligned} [u_a, u_b](z, t) &= A_b(A_a z + b_a) - A_a(A_b z + b_b) \\ &= [A_b, A_a] z + A_b b_a - A_a b_b, [X, Y] := XY - YX \end{aligned} \quad (7)$$

부호 규약. 선형 벡터장 $X(z) = Az, Y(z) = Bz$ 에 대해 벡터장 괄호는 $[X, Y](z) = BAz - ABz = [B, A] z$ 가 되어 행렬 교환자와 부호가 반대다. 이는 벡터장의 Lie 대수와 행렬 Lie 대수 사이의 표준적인 반동형 관계이며, 식 (7) 의 표기는 이를 반영한 것이다.

핵심 (상호작용에는 자유 파라미터가 없다). 식 (7) 의 우변은 전적으로 단일 섭동 생성원 (U_a, V_a, b_a) 와 (U_b, V_b, b_b) 로 결정된다. 쌍 (a,b) 로 색인되는 파라미터가 존재하지 않는다. 따라서 학습에서 한 번도 함께 관측되지 않은 쌍에 대해서도 상호작용이 계산된다.

3.4.4 반대칭 게이트

괄호는 반대칭이다: $[u_a, u_b] = -[u_b, u_a]$. 그런데 조건 P 는 순서 없는 집합이므로 모델 출력은 $a \leftrightarrow b$ 교환에 대해 대칭이어야 한다. 게이트를 반대칭으로 구성하면 두 반대칭의 곱이 대칭이 되어 이 요구가 구조적으로 만족된다.

$$\Lambda(a, b, t) = w(e_a, t) \odot m(e_b, t) - w(e_b, t) \odot m(e_a, t) \in \mathbb{R}^d$$

$$\Lambda(a, b, t) = -\Lambda(b, a, t) \text{ (반대칭)} \quad (8)$$

$$\Lambda(a, a, t) = 0 \text{ (자기 상호작용 소거)}$$

게이트를 스칼라가 아닌 원소별 벡터($\in \mathbb{R}^d$)로 두어 잠재 방향마다 상호작용 강도를 다르게 허용한다. w, m 은 작은 MLP 이다.

3.4.5 전체 속도장

$$v_\theta(z, t, P) = \underbrace{\sum_{\{a \in P\}} u_a(z, t)}_{\text{가법 항}} + \underbrace{\sum_{\{\{a,b\} \subseteq P\}} \Lambda(a, b, t) \odot [u_a, u_b](z, t)}_{\text{상호작용 항}} \quad (9)$$

둘째 합은 P 의 **순서 없는 쌍**에 대한 합이다. 식 (3)에 비추어 보면 첫 항은 BCH 전개 0차 항이고, 둘째 항은 1차 보정항에 학습된 게이트를 곱한 것이다. $|P| \geq 3$ 에서는 중첩 괄호로 고차 항을 추가할 수 있으나, 본 논문의 데이터는 $|P| \leq 2$ 이므로 2차 절단을 사용한다.

3.5 성질

Proposition 1 (순열 불변성). $v_\theta(z, t, P)$ 는 P 의 원소 나열 순서에 무관하다.

증명. 첫 항은 집합 위의 합이므로 자명하다. 둘째 항에서 a 와 b 의 역할을 바꾸면 $\Lambda(b, a, t) \odot [u_b, u_a] = (-\Lambda(a, b, t)) \odot (-[u_a, u_b]) = \Lambda(a, b, t) \odot [u_a, u_b]$ 이다. 따라서 각 항은 순서 없는 쌍 $\{a, b\}$ 의 함수로 잘 정의된다.

Proposition 2 (가법성의 정확한 복원). 모든 $a, b \in P$ 에 대해 $[A_a, A_b] = 0$ 이고 $A_b b_a = A_a b_b$ 이면 $v_\theta(z, t, P) = \sum_{a \in P} u_a(z, t)$ 가 정확히 성립한다.

증명. 가정에 의해 식 (7) 의 우변이 항등적으로 0 이 되므로 상호작용 항이 소거된다. 즉 가법 모델은 본 모델의 부분 모형이며, 근사가 아니라 정확한 특수화다.

Proposition 3 (대조군 불변성). $v_\theta(z, t, \emptyset) = 0$ 이며, 따라서 모델은 대조군 분포를 자기 자신으로 옮긴다.

증명. 두 합 모두 공집합 위의 합이므로 0 이다. 이는 학습으로 획득되는 성질이 아니라 구조적 보장이다.

Proposition 4 (단일 섭동의 직접 감독). $|P| = 1$ 이면 $v_\theta(z, t, \{a\}) = u_a(z, t)$ 이다. 즉 단일 섭동 조건은 상호작용 항의 개입 없이 생성원 u_a 를 직접 감독한다.

증명. 쌍의 집합이 공집합이므로 상호작용 항이 없다.

Proposition 4 는 학습 설계에 직접 쓰인다 (3.6.3절). 다만 단일 조건이 학습에서 제외되는 평가 설정에서는 이 감독이 사라지고, u_a 는 a 를 포함하는 다른 조합으로부터 학습되어야 한다. 이 경우에도 모델은 정의되지만 체제가 달라진다.

Proposition 5 (BCH 대응). 상호작용 항은 개별 섭동 흐름을 합성했을 때 나타나는 가법성 이탈의 1차 항과 같은 형태다.

증명. 식 (3) 에서 $\Phi_{\{u_a\}}^s \odot \Phi_{\{u_b\}}^s$ 의 생성원은 $u_a + u_b + (s/2)[u_a, u_b] + O(s^2)$ 이다. 식 (9) 의 상호작용 항은 이 1차 보정항에서 상수 $s/2$ 를 학습 가능한 반대칭 게이트 Λ 로 대체한 형태다. 즉 모델은 BCH 전개 2차 절단을 게이트로 매개변수화한다.

Proposition 6 (보지 못한 쌍으로의 외삽). 쌍 (a, b) 로 색인되는 파라미터가 존재하지 않으므로, 두 구성 섭동의 표현이 학습되어 있는 한 모델은 임의의 쌍에 대해 결정적인 상호작용을 산출한다.

증명. 식 (7) 과 (8) 에 의해 상호작용 항은 함수 $F(\theta_a, \theta_b)$ 의 형태이며 $\theta_a = (U_a, V_a, b_a, e_a)$ 는 단일 섭동의 표현이다. 쌍 단위 룩업이나 쌍 임베딩이 없다. 따라서 (a, b) 가 함께 관측된 적 없어도 상호작용이 계산된다.

범위의 한정. Proposition 6 은 보지 못한 조합에 대한 진술이지 보지 못한 섭동에 대한 진술이 아니다. e_a 가 색인 임베딩이면 학습에 없던 유전자는 다룰 수 없다. 유전자 특징(GO, 공발현)으로 e_a 를 매개변수화하면 후자로 확장되며, 이는 본 논문의 범위 밖이다.

Proposition 7 (흐름 사상의 affine 성과 전이 연산자). v_θ 가 z 에 대해 affine 이므로 시간 1 흐름 사상은 affine 이며, 각 조건은 하나의 행렬과 하나의 벡터로 요약된다.

$$\begin{aligned} \text{전체 계수: } A_P(t) &= \sum_a A_a(t) + \sum_{\{a,b\}} \text{diag}(\Lambda) [A_b, A_a](t) \\ \beta_P(t) &= \sum_a b_a(t) + \sum_{\{a,b\}} \Lambda \odot (A_b b_a - A_a b_b) \end{aligned} \quad (10)$$

$$\text{해: } z(1) = M(P) z(0) + m(P)$$

$$M(P) = T\text{-exp}(\int_0^1 A_P(t) dt), m(P) = \int_0^1 M_{\{1 \leftarrow s\}}(P) \beta_P(s) ds$$

증명. 선형 시변 ODE $\dot{z} = A_P(t) z + \beta_P(t)$ 의 해는 상태전이행렬(시간 순서 지수)로 표현된다. 수치 적분 격자에서 $M(P) \approx \prod_i \exp(A_P(t_i) \Delta t)$ 로 추출할 수 있다.

따라서 **섭동 하나가 행렬 하나가** 된다. $M(P)$ 의 고유분해는 어떤 잠재 모드가 증폭·감쇠·회전하는지를 직접 준다. 이는 사후 해석이 아니라 모델 구조에서 도출되는 양이다.

3.5.1 계산 복잡도

핵심은 $A \in \mathbb{R}^{d \times d}$ 를 **한 번도 구성하지 않는** 것이다. 저랭크 인수를 순서대로 적용한다.

$$\begin{aligned}
 u_a(z) &= U_a (V_a^T z) + b_a O(d r) \\
 A_b A_a z &= U_b (V_b^T U_a) (V_a^T z) O(d r + r^2) \\
 \vdash r \times r, \text{ 배치 내 재사용 가능 } \vdash
 \end{aligned}
 \tag{11}$$

표본당 총비용 $O(|P| d r + |P|^2 (d r + r^2))$ (A 를 명시하면 $O(d^2)$)

3.6 학습

3.6.1 커플링

작 정보 없으므로 커플링을 추정해야 한다. 각 반복에서 대조군 미니배치와 조건 P 의 섭동 미니배치 사이의 이산 최적수송 문제를 풀고, 그 계획에서 쌍을 추출한다.

$$\pi^* = \operatorname{argmin}_{\pi \in \Pi(a, b)} \sum_{i,j} \pi_{ij} \|z_0^i - z_1^j\|^2 \quad (12)$$

$(z_0, z_1) \sim \pi^*$ 로부터 식 (2)의 보간 경로와 목표 속도를 구성한다.

독립 커플링은 경로를 교차시켜 목표 속도의 분산을 키운다. OT 커플링은 이를 완화하며, 본 설정에서는 선택이 아니라 데이터 구조가 요구하는 부품이다.

3.6.2 목적함수

$$L = L_{\text{FM}} + \gamma_d L_{\text{dist}} + \gamma_s L_{\text{spec}} + \gamma_g L_{\text{gate}} \quad (13)$$

$L_{\text{FM}} = E \|v_\theta(z_t, t, P) - (z_1 - z_0)\|^2$ 식 (2)

$L_{\text{dist}} = \text{MMD}^2(\{\psi(x_1)\}_{t=1}, \{x_1\})$ 표본 수준 분포 정합

$L_{\text{spec}} = \sum_a \|A_a\|_{F^2}$ 스펙트럼 폭주 억제

$L_{\text{gate}} = \sum_{\{a,b\}} \|\Lambda(a, b, \cdot)\|_1$ 상호작용 희소성

L_{gate} 는 임의의 정칙화가 아니라 측정된 사실에 근거한 사전분포다. Norman의 125개 이중 섭동 중 노이즈 바닥 보정 후 실질적 비가법성을 보이는 것은 소수이며, 그 소수도 특정 유전자에 집중되어 있다. 상호작용이 희소하다는 것은 가정이 아니라 관측이다.

L_{spec} 는 저랭크 인수로부터 A 를 구성하지 않고 계산한다: $\|U V^T\|_{F^2} = \text{tr}(V^T U U^T U) = \text{tr}(U^T U V V^T)$ 이며 이는 $r \times r$ 행렬 두 개의 곱으로 $O(d r^2)$ 에 얻어진다.

3.6.3 학습 스케줄

Proposition 4에 따라 단일 섭동 조건은 상호작용 항 없이 u_a 를 직접 감독한다. 이를 이용해 두 단계로 학습한다. ① 단일 조건만으로 생성원을 안정화한다. ② 조합 조건을 포함해 전체를 학습하며 게이트를 연다. 순서를 뒤집으면 초기의 불안정한 생성원 위에서 게이트가 잘못된 상호작용을 학습한다.

3.7 추론

$$\frac{dz}{dt} = v_\theta(z, t, P), \quad z(0) = \varphi(x_0), \quad x_0 \sim \mu_0, \quad t: 0 \rightarrow 1 \quad (14)$$

$x_1 = \psi(z(1))$ (PCA 역변환, 정확)

적분은 고정 스텝 RK4로 수행한다. 예측은 세포 집합이므로 평균 수준 지표와 분포 수준 지표를 모두 산출할 수 있다. 또한 식 (10)의 $M(P)$ 를 추출하면 조건별 선형 요약과 스펙트럼 해석이 함께 얻어진다.

3.8 설계 선택의 실증적 근거

본 절의 수치는 Norman 데이터(K562 CRISPRa)에서 모델 학습 이전에 측정한 것이며, 세 가지 설계 결정을 뒷받침한다. 상대 E-distance 는 대조군 대비 값으로, 0 은 완벽, 1 은 대조군과 동일함을 뜻한다.

(i) 가법성을 구조로 내장하는 근거

가법 기준선 $\delta_a + \delta_b$ 는 관례 지표에서 이미 포화 수준이다. cell-eval 기준 Pearson $\Delta = 0.8990$, 판별 점수 $= 0.9759$ 이다. 모델이 가법성을 처음부터 다시 학습하는 데 용량을 쓸 이유가 없다. Proposition 2 에 의해 가법 모델은 본 모델의 정확한 부분 모형이다.

(ii) 생성원을 affine 으로 제한하는 근거

기준선은 모두 대조군 구름의 평행이동이므로 분포의 모양은 대조군 그대로다. 남은 거리가 평균 때문인지 모양 때문인지 분해하면 다음과 같다.

split	최고 기준선	oracle_mean (참 delta 평행이동)	평균+공분산 정합	노이즈 바닥
additive	0.1966	0.0443	0.0037	-0.0035
combinations	0.2729	0.0429	0.0051	-0.0024

평균+공분산만 정합해도 노이즈 바닥에 도달한다 (additive 에서 0.0037 vs -0.0035). 즉 이 표본 크기에서 2차 모멘트를 넘는 분포 구조는 식별되지 않는다. 또한 회수 가능한 거리의 76% (additive) / 84% (combinations) 가 **평균 예측**에 있다. 따라서 표현력을 고차 분포 모델링이 아니라 조합 구조에 배분한다. affine 제한은 이 관측의 직접적 귀결이다.

(iii) 상호작용 희소성 사전분포의 근거

이중 섭동의 가법 잔차를 조건별 표본 수에 맞춘 귀무분포로 보정해 측정하면, 실질적 비가법성을 보이는 조합은 소수이며 특정 유전자에 집중된다. 이는 L_gate 의 L1 사전분포를 정당화한다.

3.9 선행 연구와의 관계

방법	조합 처리	상호작용 항	보지 못한 쌍의 외삽 근거
CPA	잠재 벡터 덧셈	없음 (가법)	없음
GEARS	유전자 그래프 GNN	암묵적	그래프 이웃
CellFlow	set attention / DeepSets → 조건 벡터	인코더가 암묵 학습	임베딩 유사도
scDFM	multi-hot + adapter 주입	트랜스포머가 암묵 학습	임베딩 유사도
LieCFM (본 논문)	동역학을 대수적으로 합성	Lie 괄호 자유 파라미터 없음	구성 단일 섭동의 생성원이 결정

선행 방법은 모두 조합을 **하나의 조건 벡터로 압축**한 뒤 네트워크에 주입한다. 압축의 형태가 attention 이든 DeepSets 이든 multi-hot 이든, 조합 구조는 인코더 내부에 놓고 상호작용은 학습으로만 얻어진다. 본 논문은 압축하지 않는다. 각 섭동을 동역학의 생성원으로 두고, 합성을 Lie 대수의 연산으로 수행한다.

3.10 왜 Flow Matching 이어야 하는가

근거	내용
구조적	Lie 괄호는 벡터장 의 성질이다. 조건별 평균 변화 δ 를 직접 회귀하는 모델에는 괄호를 취할 대상 자체가 없다. 식 (7) 의 상호작용 항은 ODE 정식화 없이는 정의될 수 없다
데이터	대조군과 섭동군 세포는 짝지어져 있지 않다. 세포 단위 회귀가 불가능하며, Flow Matching 과 최적수송 커플링이 짝을 구성하는 수단이다

검증 가능한 예측 (이론이 장식이 아님을 보이는 실험). 모델이 산출하는 상호작용 강도 $E(a,b) = \parallel \Lambda(a,b,\cdot) \odot [u_a, u_b] \parallel$ 가 데이터에서 독립적으로 측정한 비가법성 강도와 상관하는지 검정한다. 상관이 관측되면 대수적으로 유도한 epistasis 가 실측 epistasis 와 일치함이 확인된다. 관측되지 않으면 이론적 주장을 축소한다.

본 절의 수치는 저장소의 실행 가능한 코드에서 생성된다: liecfm/eval.py (기준선), liecfm/headroom.py (분해), liecfm/eval_celleval.py (cell-eval 대조), liecfm/latent_choice.py (잠재 공간 선택).