

LT-VAE + LieCFM

조합 섭동 예측 — 재시작 명세서 (Handoff)

PGFM 프로젝트 · 2026-08-11 · 코드 전면 재작성을 위한 인수인계 문서

이 문서의 용도. 코드베이스를 전부 지우고 처음부터 다시 작성하기 위한 단일 참조 문서다. 여기 적힌 **측정값은 재도출할 필요가 없고, 폐기된 방향은 다시 시도하지 않는다.** 새 세션에서 이 문서만 있으면 구현을 시작할 수 있도록 작성했다.

1. 프로젝트 정의

항목	내용
목표	조합 유전자 섭동(A+B)의 단일세포 발현 응답 예측. 학습에서 보지 못한 조합으로 일반화
학회	ICLR 본회의 수준
주 데이터	Norman (K562 CRISPRa). 84,986 세포 × 19,264 유전자, log1p 정규화본
비교 대상	scDFM (arXiv:2602.07103) Table 1 — Norman additive split의 현 SOTA
기간	약 5주
핵심 난이도	(1) 대조군/섭동 세포가 짜지어져 있지 않음 (2) 함께 관측된 적 없는 쌍의 상호작용을 외삽해야 함

2. 측정으로 확정된 사실 — 재도출 불필요

2.1 데이터 구조

항목	Norman	Combosciplex
cells × genes	84,986 × 19,264	63,378 × 27,518
control 세포	7,275 (condition = 'ctrl')	1,451
single / double	101 / 125	6 / 25
두 single 을 모두 보유한 double	125 / 125	7 / 25
condition 당 세포 수	double 46–1,005 (중앙 248)	476–3,298
t=0 guide abundance	없음	없음

Combosciplex 는 조합 벤치마크로 쓸 수 없다. 25개 double 중 18개는 구성 약물 중 하나 이상이 single 조건으로 존재하지 않아 가법 baseline 조차 계산되지 않는다. ood split 5개 중 분해 가능한 것도 3개뿐이다. Norman 만 주 데이터로 쓰고, Combosciplex 를 쓴다면 '다른 modality 에서의 분포 이동 일반화' 로만 프레임링한다.

2.2 Split — scDFM 정의를 그대로 쓴다

자체 설계 split 은 '저자가 만든 split 에서 저자의 방법이 이겼다'는 반박에 답할 수 없다. 선행 연구의 정의를 이식하고, 원본 산출물과 대조 검증한다.

split	정의	규모
additive	double 125개를 셔플해 30% test. single 은 전부 train	5 fold · train 88 / test 37
combinations	additive test 앞 15개만 test, 그 유전자의 single 도 test 로 이동	test 15d + held-out single 21–26

scDFM src/data_process/data.py 131-142 행 — 그대로 이식할 것

for i in range(5):

```

np.random.seed(42 + i) # legacy RandomState. NEP 19 로 스트림 동결됨
shuffled = double_perturbation.copy() # np.unique 로 정렬된 double 목록
np.random.shuffle(shuffled)
k = int(len(shuffled) * 0.3)
test, train = shuffled[:k], shuffled[k:]

# combinations: additive 에서 결정적으로 파생
test_doubles = fold['test'][:15]
held_genes = {g for p in test_doubles for g in p.split('+')}
test = test_doubles + [g + '+ctrl' for g in held_genes]

```

난수 방식을 바꾸지 말 것. `np.random.seed` / `shuffle` 은 legacy `RandomState` 이고 NumPy 가 NEP 19 에서 스트림을 동결했다. `np.random.default_rng` 계열은 버전 간 재현이 보장되지 않는다. 생성한 `split` 은 매 실행 `data/norman/split_results.pkl` 과 대조하고 불일치 시 중단한다 (현재 5개 fold 전부 일치 확인됨).

원본의 세 번째 방식 **unseen** 은 이식하지 않는다: 시드 없는 `random.shuffle` 을 쓰고, 원본 119행 **if `split_method` == 'additive' or 'combinations'**: 이 항상 참이라 해당 분기가 도달 불가능한 죽은 코드다.

2.3 설계를 규정하는 측정값

측정	결과	설계 함의
가법 baseline 의 관례 지표	top-20 DE Pearson 중앙 0.977 cell-eval Pearson Δ 0.8990	관례 지표는 포화 되어 모델을 구분하지 못한다. 판정에 쓰지 말고 보고만 한다
헤드룸 분해 (상대 E-distance)	평균 예측이 76% (additive) / 84% (combinations)	표현력을 고차 분포 모델링이 아니라 조건→효과 사상 에 배분한다
평균+공분산 정합 vs 노이즈 바닥	0.0037 vs -0.0035	이 표본 크기에서 2차 모멘트를 넘는 분포 구조는 식별되지 않는다
HVG 커버리지 (DE20 합집합)	raw_variance 2000 → 38.1% (조건별 최소 5%) dispersion 2000 → 23.9%	HVG 부분집합은 유전자공간 지표를 온전히 낼 수 없다. dispersion 은 더 나쁘다 (DE20 이 non-dropout 기준이라 고발현 편향)
잠재 차원별 delta 복원	128 → 0.3441, 512 → 0.3075 노이즈 바닥 0.2983	128 에서 실제 손실은 $\sqrt{(0.344^2-0.298^2)} \approx 0.17$. 512 로 4배 늘려도 0.07 까지만 준다
기저 비교 (rank 128)	세포 PCA 0.3082 vs 학습 delta 기저 0.3233	학습된 선형 기저가 세포 PCA 보다 낮지 않다. 남은 성분은 조건 고유 방향이라 어떤 방법도 도달 못 하는 상한
on-target 유도 강도	median logFC 0.364 · >0.5 는 34/101 · <0.15 가 28/101	125 double 중 40개가 한쪽 이상 사실상 무섭동. 유효 평가 대상은 양쪽 강섭동 85개

3. 폐기된 방향 — 다시 시도하지 말 것

방향	폐기 근거
질량(mass) 채널 · 성장률 학습	세포 수 잔차의 72%가 library skew , epistasis 분산 σ_E^2 의 95% CI 가 0을 포함 (bootstrap $P(\sigma_E^2 \leq 0) = 0.25$). t=0 guide abundance 가 없어 분리 불가. 게다가 VGFM (NeurIPS 2025) 이 velocity+growth 결합 FM 을 이미 출판했다
apoptosis 시그니처로 viability 측정	scRNA-seq 는 죽은 세포를 캡처하지 않는다. 시퀀싱된 세포는 정의상 apoptosis 를 겪지 '않은' 세포다. positive control 실패 — BCL2L1(+0.40 유도) z=+0.4, BAK1(+0.53) z=+2.2. 구조적 한계이며 데이터를 더 모아도 해결되지 않는다
자체 설계 hard split	cherry-pick 의혹에 답할 수 없고, np.random.default_rng 는 스트림 재현이 보장되지 않는다
PCA 인코더 + affine 생성원	모델 전체가 end-to-end affine 이 된다. 학습된 모델에서 실증: $\ T(z_1+z_2-z_3) - (T(z_1)+T(z_2)-T(z_3))\ / \ \cdot\ = \mathbf{1.6e-07}$. 즉 $x^T W^T M(P) W(x-x_c) + c$ 이고, ODE 도 flow matching 도 표현력에 기여하지 않는다

4. 아키텍처 명세 — LT-VAE + LieCFM

PCA 를 학습된 패스웨이 cross-attention 오토인코더로 교체하고, 잠재 공간의 조합 동역학을 Lie 대수로 정식화한다. 기여가 두 개다: (i) 패스웨이 병목 표현 학습, (ii) 대수적 조합.

4.1 인코더 P-CAB (Pathway-guided Cross-Attention Bottleneck)

쿼리 $Q_{enc} \in \mathbb{R}^{K \times d_k}$ 학습 가능한 K 개 패스웨이 토큰
 키/값 $K_{enc}, V_{enc} \in \mathbb{R}^{G \times d_k}$ 유전자 발현 $x \in \mathbb{R}^G$ 의 임베딩
 $H_{enc} = \text{softmax}(Q_{enc} K_{enc}^T / \sqrt{d_k} + \lambda \cdot M_{GRN}) V_{enc} \in \mathbb{R}^{K \times d_v}$
 $M_{GRN} \in \mathbb{R}^{K \times G}$ 패스웨이-유전자 연결 (연결 0, 미연결 -inf)
 λ 학습 가능한 스칼라 — soft prior. 고정 마스크가 아니다
 $\mu = W_\mu \text{Flatten}(H_{enc}) + b_\mu \in \mathbb{R}^d$
 $\log \sigma^2 = W_\sigma \text{Flatten}(H_{enc}) + b_\sigma \in \mathbb{R}^d$
 $z_0 = \mu + \epsilon \odot \exp(\frac{1}{2} \log \sigma^2), \epsilon \sim N(0, I)$

복잡도가 $O(G^2)$ 에서 $O(G \cdot K)$ 로 내려간다. $G=19,264$ 에서 self-attention 은 불가능하다.

4.2 잠재 동역학 LieCFM

생성원 $u_a(z, t) = A_a(t) z + \beta_a(t)$, $A_a = U_a V_a^T$, rank r (affine)
 또는 $u_a(z, t) = \text{NeuralField}(z, e_a, \tau(t))$ (nonlinear)
 Lie 괄호 $[u_a, u_b](z, t) = (A_b A_a - A_a A_b) z + A_b \beta_a - A_a \beta_b$ (affine)
 $[u_a, u_b](z) = J_{\{u_b\}}(z) \cdot u_a(z) - J_{\{u_a\}}(z) \cdot u_b(z)$ (nonlinear)
 torch.func.jvp 2회, Jacobian 물질화 없음
 게이트 $\Lambda(a, b, t) = w(e_a, t) \odot m(e_b, t) - w(e_b, t) \odot m(e_a, t)$ (반대칭)
 속도장 $v_\theta(z, t, P) = \sum_{a \in P} u_a(z, t) + \sum_{\{a, b\} \subseteq P} \Lambda(a, b, t) \odot [u_a, u_b](z, t)$
 적분 $z_1 = z_0 + \int_0^1 v_\theta(z_t, t, P) dt$ RK4

affine 과 nonlinear 를 설정 축으로 두고 둘 다 측정한다. affine 위의 괄호는 행렬 교환자이고 이는 제어이론의 bilinear Koopman 표준형으로 이미 알려져 있다. 학습된 **비선형** 벡터장의 괄호를 forward-mode AD 로 계산하는 것이 새로운 부분이다. 다만 affine 이 이기면 그것도 보고할 결과다 — '고차 동역학이 필요 없다'는 발견이 된다.

4.3 디코더 E-RCA (Epistatic Response Cross-Attention)

$H_1 = \text{Reshape}(z_1) \in \mathbb{R}^{K \times d_v}$
 쿼리 $Q_{dec} \in \mathbb{R}^{G \times d_k}$ 유전자별 임베딩
 키/값 $K_{dec} = H_1 W_K, V_{dec} = H_1 W_V$
 $_dec = \text{softmax}(Q_{dec} K_{dec}^T / \sqrt{d_k} + \gamma \cdot M_{GRN}^T) V_{dec} \in \mathbb{R}^{G \times d_v}$
 $x_1[g] = w \cdot _dec[g] + b_g$ $w \in \mathbb{R}^{d_v}$ 공유, $b \in \mathbb{R}^G$

출력층 주의. $x = W_{out} \cdot \text{Flatten}(_dec)$ 로 쓰면 $W_{out} \in \mathbb{R}^{19,264 \times (19,264 \cdot 64)}$ 가 되어 **약 237억 파라미터**가 된다. 반드시 위와 같이 **유전자별 사영**(공유 w + 유전자별 bias, 약 19K 파라미터)으로 구현할 것.

4.4 구조적으로 보장되는 성질 (구현 후 수치로 검증할 것)

성질	내용	검증 방법
순열 불변	$v(z,t,\{a,b\})$ 가 $a \leftrightarrow b$ 교환에 불변. 반대칭 게이트 $\times$ 반대칭 괄호 = 대칭	$\max v(a,b)-v(b,a) = 0$ 이어야 함
가법 정확 복원	생성원이 가환이면 상호작용 항이 정확히 0. 가법 모델은 근사가 아니라 부분 모형	게이트를 0 으로 두면 <code>interaction='none'</code> 과 완전 일치
대조군 불변	$v(z,t,\emptyset) = 0$. 학습이 아니라 구조가 보장	$\max v(\emptyset) = 0$
single 직접 감독	$ P =1$ 이면 상호작용 항이 구조적으로 없어 u_a 가 직접 감독됨	$ P =1$ 에서 commutator 와 none 이 동일 출력
미관측 쌍 외삽	쌍으로 색인되는 파라미터가 없음. 상호작용이 구성 single 의 생성원으로 결정됨	코드 리뷰 (쌍 록업 테이블이 없을 것)

범위 한정: 위 다섯 번째는 **미관측 조합**에 대한 진술이지 **미관측 섭동**이 아니다. e_a 가 색인 임베딩이면 학습에 없던 유전자는 다룰 수 없다.

5. 학습 명세

Stage 1 — VAE 오토인코딩 (LieCFM 비활성)

$$L = E \|x - \hat{x}\|^2 + \beta \cdot D_{KL}(N(\mu, \sigma^2) \| N(0, I))$$

Stage 2 — 잠재 Flow Matching

커플링: 조건별 미니배치 (Unbalanced) OT 로 (z_0, z_1) 쌍 추출

$$z_t = (1-t)z_0 + tz_1, \text{ 목표 속도} = z_1 - z_0, t \sim U[0,1]$$

$$L = E \|v_\theta(z_t, t, P) - (z_1 - z_0)\|^2 + \gamma_s \sum_a \|A_a\|_F^2 + \gamma_g \|\Lambda\|_1$$

단일 섭동 위망업 후 조합 포함 전체 학습 (single 이 u_a 를 직접 감독하므로)

항목	권고	근거
Stage 2 에서 인코더	동결하지 말고 미세조정을 함께 시도	동결하면 잠재가 재구성에 최적화된다. 인코더를 학습하는 진짜 이유는 '생성원이 잘 합성되는 공간'을 찾는 것이고 이는 재구성 목적과 다르다
게이트 L1 (γ_g)	포함	실질적 비가법 조합이 소수이고 특정 유전자에 집중된다는 것이 측정된 사실
스펙트럴 정규화	$\ L \text{diag}(s) R^T\ _F^2 = \text{tr}((\text{diag}(s)R^T \text{diag}(s))(L^T L))$ 로 계산	$A \in R^{d \times d}$ 를 만들지 않는다. $m \times m$ 두 개의 곱으로 $O(d \cdot m^2)$

6. 평가 프로토콜과 목표선

6.1 내부 하네스 (모델 개발용)

edist_rel 잠재 공간 energy distance / control 대비. 0=완벽, 1=control 과 동일

resid_R2 가법 잔차를 얼마나 맞추는가. 가법 예측은 정의상 0

$$r = m_{AB} - m_A - m_B + m_{ctrl}$$

$$r_{\text{hat}} = m_{\text{hat}} - m_A - m_B + m_{ctrl}$$

$$R^2 = 1 - (\|r_{\text{hat}} - r\|^2 - E_{\text{noise}}) / (\|r\|^2 - E_{\text{noise}})$$

r_de20 top-20 DE Pearson(delta). 포화되므로 보고만 하고 판정에 쓰지 않는다

noise floor 는 세포 수에 의존한다. 조건별 세포 수가 46~1,005 로 20배 차이 나므로 단일 임계값을 쓰면 소수 세포 조합이 전부 가짜 양성인 된다. control 세포를 4그룹으로 나눈 귀무분포를 **크기 정합**시켜 E_{noise} 의 보정 계수 λ 를 구해야 한다 ($n_{\text{eff}}=32$ 에서 1.65, $n_{\text{eff}}=268$ 에서 1.05 로 측정됨).

6.2 넘어야 할 목표선 (측정값)

split	baseline	r_de20	edist_rel ↓	resid_R2 ↑
additive	control	—	1.0000	-5.5985
additive	additive $\delta_A + \delta_B$	0.9770	0.2153	0.0000
additive	per-gene scaled	0.9795	0.1841	0.5313
additive	ridge additive	0.9846	0.1904	0.7201
combinations	가법 계열	—	계산 불가	계산 불가
combinations	ridge additive	0.9808	0.2487	0.4092

LieCFM 이 넘어야 할 선

additive edist_rel < **0.1841** · resid_R2 > **0.7201**

combinations edist_rel < **0.2487** · resid_R2 > **0.4092**

combinations 에서 가법 계열이 계산 불가한 이유는 test double 의 single 이 학습에서 제외되기 때문이다. 하네스가 자동 감지해 건너뛰도록 구현할 것.

6.3 외부 비교 — scDFM Table 1 대조

scDFM Table 1 은 **cell-eval 0.5.42** 의 MetricsEvaluator 출력이다. 직접 비교하려면 같은 패키지같은 프로토콜이어야 한다.

1. HVG 5000 + 섭동 표적 강제 포함 → adata subset (모델 입력 공간)
2. condition 'ctrl' → 'control' 치환, Drug1/Drug2 파생
3. mode='test' ← split_results[fold]['test'], fold = 1
adata_test = (mode=='test') | (control==1)
4. HVG 1000 on adata_test → subset (평가 공간)
5. control 세포를 pred/real 양쪽에 동일하게 포함
각 test 조건: pred = 무작위 control 128개에 예측 적용, real = 실제 세포 전부
6. MetricsEvaluator(control_pert='control', pert_col='perturbation').compute()

환경: python 3.11 별도 (cell-eval 0.5.42 가 python<3.13 요구). 버전 고정 필수

Table 1 열	cell-eval 지표명	논문 Additive	우리 재현	상대차
MSE	mse	0.00448	0.004442	0.86%
MAE	mae	0.02276	0.022542	0.96%
Pearson Δ	pearson_delta	0.9024	0.898994	0.38%
DS	discrimination_score_l1	0.9686	0.975895	0.75%
DE-Spearman ρ	de_spearman_sig	0.5564	0.588215	5.72%

Table 1 의 8개 열 중 5개만 cell-eval 에서 나온다. L2, 두 번째 Pearson Δ, Pearson Δ₂₀ 는 cell-eval 0.5.42 의 27개 지표에 없고 scDFM 공개 저장소에도 구현이 없다. 정의를 확정하기 전까지 그 세 열은 비교하지 않는다.

위 재현은 **단일 시드 1회**다. 조건당 control 128개를 무작위로 뽑으므로 표본 변동이 있고, 1% 미만 차이가 그 변동 안인지 **아직 측정하지 않았다**. 시드 반복이 필요하다.

7. 구현 시 반드시 피할 함정

함정	증상 / 실측	대처
sklearn PCA.fit_transform	randomized SVD 의 U·S 를 반환하는데 이는 $(X - \text{mean}) @ W^T$ 와 근사적으로만 같다. 잠재 Z 와 디코더 W 가 어긋난다. 실측 조건 delta 투영 상대오차 1.6e-02	fit 후 transform 을 명시 호출 . 그러면 ~1e-06
ctrl 을 기준으로 한 정규화	'ctrl' 은 여러 대조 guide 를 합친 라벨(7,275세포)이라 단일 construct(~250세포)와 직접 비교하면 125개 중 124개가 같은 부호로 나오는 artifact 발생	class 내 중앙값 센터링을 쓸 것
단일 noise floor 임계값	조건별 세포 수가 46~1,005 로 20배 차이. n_eff=32 에서 null excess 1.65, n_eff=268 에서 1.05	크기 정합 귀무분포로 λ 를 보간
디코더 출력층 Flatten	$W_{\text{out}} \in \mathbb{R}^{G \times (G \cdot d_v)} \rightarrow$ 약 237억 파라미터	유전자별 사영으로 구현
np.random.default_rng	NumPy 가 Generator 스트림의 버전 간 호환을 보장하지 않는다	split 생성에는 legacy RandomState 사용
HVG 부분집합 + 유전자공간 지표	raw_variance 2000 은 DE20 합집합의 38%만 포함, 조건별 최소 커버리지 5%	n_hvg=None(전체) 을 기본 옵션으로 제공하고, 부분집합을 쓸 때 커버리지를 함께 보고

8. 설정으로 빼야 할 ablation 축

실험에서 바뀔 수 있는 값은 코드에 상수로 박지 않는다. 모든 실행은 사용한 설정 전체를 결과 폴더에 저장하고, 명령줄에서 점 표기로 덮어쓸 수 있어야 한다.

그룹	항목
data	n_hvg (기본 3000, None=전체), hvg_criterion (raw_variance dispersion), force_include_targets, n_pca / latent_dim, GRN 컬렉션과 K
model	field (affine nonlinear), interaction (none commutator free_mlp), rank r, embed_dim, gate_dim (스칼라 원소별), stable_param, max_combo, d_k / d_v, 패스웨이 수 K
train	coupling (ot uot random), ot_reg, batch_size, conds_per_batch, lr, epochs, warmup_single_epochs, β (KL), γ_s , γ_g , stage2_freeze_encoder , ode_steps, ode_method, seed
eval	split (additive combinations), fold, n_sub, gene_space (modeled all), n_gen_cells

대조군으로 반드시 넣어야 할 두 가지.

- ① **interaction=free_mlp** — 상호작용을 자유 MLP 로 둔 것. 이게 commutator 와 비슷하면 **대수적 형태의 기여가 없다는 뜻이다.**
- ② **flow 제거** — δ 를 직접 회귀. 리뷰어가 반드시 묻는다.

9. 구현 순서와 판정 기준

단계	내용	판정
0	데이터 전처리 · split 이식 · 평가 하네스 · 기준선	split 이 원본과 일치, 기준선이 6.2절 표를 재현
1	잠재 FM 코어 (interaction=none)	가법 baseline 수준 재현
2	교환자 항 추가, on/off 및 affine/nonlinear 비교	combinations 에서 목표선 통과 여부. 여기서 설계의 생사가 갈린다
3	P-CAB / E-RCA 로 인코더·디코더 교체	Stage 1 재구성 품질 + 2단계 결과 유지
4	Stage 2 동결 vs 미세조정	잠재를 대수에 맞춰 학습하는 것이 이득인가
5	free_mlp 대조군, flow 제거 대조군	대수적 형태와 flow 의 기여 분리
6	cell-eval 로 Table 1 대조	scDFM 대비 위치 확정

순서를 지킬 것. 2단계가 실패하면 인코더를 아무리 정교하게 만들어도 논문의 두 번째 기여가 성립하지 않는다. 2단계는 기존 코드 기준 반나절이면 판정된다.

10. 미결 사항

항목	상태
GRN / 패스웨이 행렬 M_{GRN}	미확보. MSigDB / Reactome / GO 중 선택, K 결정, Norman 101개 섭동 표적의 커버리지 확인 필요
Table 1 의 $L2 \cdot \text{Pearson } \Delta_{20}$ 정의	cell-eval 에 없음. Additive 행으로 정의를 역추적해 검증해야 8개 열 전부 비교 가능
cell-eval 재현의 시드 변동	단일 시드 1회만 측정. 반복해서 <1% 차이가 변동 내인지 확인 필요
패스웨이 VAE 선행 연구 포지셔닝	VEGA / expiMap / pmVAE 계열(정확한 서지 확인 필요)은 마스킹된 선형 디코더 를 쓴다. 우리는 세포마다 달라지는 어텐션 + 학습 가능한 λ, γ 로 GRN 주석 밖으로 나갈 수 있다는 점을 한 문단으로 못박아야 한다
문헌 스윕	CellFlow, scDFM, VGFM 확인됨. 2026 상반기에만 4~5편이 나왔으므로 착수 전 재확인

부속 자료: docs/LieCFM-method.pdf (Method 초안, 식 14개 · Proposition 7개), docs/fig_architecture.pdf, docs/fig_composition.pdf (논문용 벡터 그림), assets/splits_*.pkl (검증된 split), assets/norman.npz (전처리본)