

LieCFM

Lie 대수 기반 조합 Flow Matching Lie-algebraic Compositional Flow Matching

아키텍처 설계 문서 v1 · PGFM 프로젝트 · 2026-08-11

한 줄 요약. 조합 섭동을 '토큰 집합을 인코딩해 조건 벡터로 주입'하는 대신, 각 섭동이 유도하는 **속도장을 Lie 대수의 원소로 보고 대수적으로 합성**한다. 상호작용 항은 자유 네트워크가 아니라 두 속도장의 **Lie bracket**이며, 학습되는 것은 반대칭 스칼라 게이트뿐이다. 그 결과 **안 본 조합의 상호작용을 구성 single의 속도장만으로 계산**할 수 있다.

additivity = commutativity | **epistasis = non-commutativity**




그림 1. 흐름의 합성이 가법적이지 않은 이유. 두 생성원이 가환이면 조합은 정확히 가법이고, 비가환이면 그 차이가 곧 epistasis다.

1. 문제 설정

control 세포 집합과 조건 P 하의 섭동 세포 집합이 주어진다. 파괴적 측정이므로 두 집합은 **짜지어져 있지 않다**. 목표는 학습 때 보지 못한 조합에 대해 섭동 후 분포를 예측하는 것이다.

control : $x_0 \sim \mu_0$, perturbed : $x_1 \sim \mu_1^{P^*}$, $P \subseteq G$, $|G| = 101$ (Norman)

Norman 에서 $|P| \in \{1, 2\}$ — single 101개, double 125개

과제 : $P^* = \{a, b\}$ 가 학습에 없을 때 $\mu_1^{P^*}$ 를 예측

핵심 난이도는 **유전자 disjoint 하드 split**에 있다. test 조합의 두 유전자가 train의 어떤 double에도 등장하지 않으므로, 모델은 상호작용을 **single 정보만으로 외삽**해야 한다. 사전 분석에서 릿지 회귀는 이 설정에서 붕괴했다(resid_R2 -0.747). 상호작용을 별도 파라미터로 학습하는 모든 방법이 같은 취약점을 갖는다.

2. 설계 원칙 — 각 결정의 근거

이 구조의 모든 선택은 사전 분석(STEP 1-5)에서 측정한 사실에 대응한다. 임의로 고른 부분이 없다는 점이 이 설계의 성격이다.

측정된 사실	설계 결정
가법 예측이 효과의 대부분을 설명 (top-20 DE Pearson 중앙값 0.980)	가법성을 구조로 내장 . 모델이 가법을 재학습하는 데 용량을 쓰지 않는다
유전자별 스케일링만으로 resid_R2 0.463 (하드 split)	생성원의 대각 성분이 이를 자연히 표현. 별도 모듈 불필요
잠재 공간에서 응답이 노이즈 내 affine (gauss_match 0.0066 $\approx$ self_split -0.0029)	생성원을 affine으로 제한 . 남은 용량 전부를 조합 구조에 배분
실질적 비가법이 소수 조합에 집중 (18/125), 소수 유전자에 집중 (CEBPE 8/11, MAPK1 5/8)	게이트에 희소성 사전분포 (L1). 측정된 사실을 prior로 사용
하드 split에서 릿지 붕괴 (resid_R2 -0.747)	상호작용에 자유 파라미터를 두지 않음 . 구성 single이 결정
데이터가 unpaired	flow matching + OT 커플링이 선택이 아니라 필수

3. 핵심 원리

flow matching에서 각 섭동은 하나의 **속도장**을 유도한다. 속도장의 집합은 Lie bracket 아래에서 **Lie 대수**를 이루고, 흐름의 합성은 Baker–Campbell–Hausdorff 공식이 지배한다.

$$\text{Lie bracket : } [u, w](x) = (\partial w / \partial x) \cdot u(x) - (\partial u / \partial x) \cdot w(x)$$

$$\text{BCH : } \Phi_A \circ \Phi_B = \Phi_{\{ A + B + \frac{1}{2}[A, B] + (1/12)([A, [A, B]] - [B, [A, B]]) + \dots \}}$$

가법성 = 가환성. Epistasis = 비가환성.

이건 비유가 아니라 등식이다. 두 생성원이 가환이면 조합은 정확히 가법이고, 가법에서 벗어나는 정도가 곧 교환자의 크기다. 따라서 상호작용 항을 자유 MLP로 두는 대신 **대수가 강제하는 형태로** 둘 수 있다.

4. 아키텍처




그림 2. 전체 구조. 주황 경로는 섭동 조건, 파랑 경로는 세포 상태다. 빨강 블록(Lie bracket)에는 학습 파라미터가 없다.

4.1 잠재 공간

유전자 공간에서 HVG 2,000개를 고른 뒤 PCA로 $d = 128$ 차원에 사영한다. PCA는 전처리로 고정한다. 선형이므로 복원이 정확하고 오토인코더 재구성 오차 바닥이 생기지 않는다. 사전 분석에서 이 공간의 평균+공분산 정합이 노이즈 바닥과 구분되지 않았으므로, 이 공간에서 **affine**이면 **표현력이 충분하다**는 근거가 이미 있다.

4.2 섭동 임베딩

$$e_a \in \mathbb{R}^{d_e}, a \in G, d_e = 64$$

기본은 학습 가능 임베딩이다. 이 경우 **안 본 조합**은 다룰 수 있지만 **안 본 유전자**는 불가능하다. 확장으로 GO / co-expression 특징을 임베딩 초기화나 추가 입력으로 사용하면 안 본 유전자로도 확장된다.

4.3 생성원 하이퍼네트워크

$$\tau(t) = \text{Fourier feature}(t) \in \mathbb{R}^{d_t}$$

$$h_a(t) = \text{MLP}([e_a; \tau(t)]) \in \mathbb{R}^{d_h}$$

$$U_a(t) = \text{reshape}(W_U h_a(t)) \in \mathbb{R}^{d \times r}$$

$$V_a(t) = \text{reshape}(W_V h_a(t)) \in \mathbb{R}^{d \times r}$$

$$\beta_a(t) = W_\beta h_a(t) \in \mathbb{R}^d$$

$$A_a(t) = U_a(t) V_a(t)^T \leftarrow \text{절대 물질화하지 않는다}$$

$$u_a(z,t) = U_a (V_a^T z) + \beta_a \text{ 비용 } O(d \cdot r), A \text{ 를 만들면 } O(d^2)$$

rank $r \ll d$ ($r = 8 \sim 32$). 안정성을 위한 선택적 구조화 파라미터화도 제공한다. 대칭부를 음정부호로 강제하면 고윳값이 좌반평면에 놓여 흐름이 비팽창이 된다.

$$A_a = -S_a S_a^T + (P_a Q_a^T - Q_a P_a^T) \text{ (음정부호 대칭 + 반대칭)}$$

4.4 교환자 상호작용 — 이 설계의 핵심

$$[u_a, u_b](z,t) = A_b (A_a z + \beta_a) - A_a (A_b z + \beta_b)$$

$$= [A_b, A_a] z + A_b \beta_a - A_a \beta_b$$

저랭크 계산 (A 를 만들지 않는다) :

$$A_b A_a z = U_b (V_b^T U_a) (V_a^T z) \leftarrow (V_b^T U_a) \text{ 는 } r \times r$$

$$\text{비용 } O(d \cdot r + r^2)$$

이 항에는 학습 파라미터가 하나도 없다. u_a 와 u_b 가 정해지면 두 섭동의 상호작용이 결정된다. 그래서 학습 때 본 적 없는 쌍의 상호작용을 그 구성 single만으로 계산할 수 있다. 이것이 유전자 disjoint 하드 split에서 기존 방법과 갈리는 지점이다.

4.5 반대칭 게이트

bracket은 반대칭이다: $[u_a, u_b] = -[u_b, u_a]$. 그런데 조합 $\{a, b\}$ 는 순서가 없으므로 모델 출력은 $a \leftrightarrow b$ 교환에 대해 대칭이어야 한다. 게이트를 반대칭으로 만들면 두 반대칭의 곱이 대칭이 되어 자동으로 해결된다.

$$\Lambda(a, b, t) = w(e_a, t) \odot m(e_b, t) - w(e_b, t) \odot m(e_a, t) \in \mathbb{R}^d$$

$$\Lambda(a, b) = -\Lambda(b, a) \Rightarrow \Lambda \odot [u_a, u_b] \text{ 는 } a \leftrightarrow b \text{ 에 대칭 } \odot$$

$$\Lambda(a, a) = 0 \Rightarrow \text{자기 상호작용 자동 소거 } \odot$$

게이트를 원소별($\mathbb{R}^d$)로 두어 잠재 방향마다 다른 상호작용 강도를 허용한다.

4.6 전체 속도장

$$v_\theta(z, t, P) = \sum_{a \in P} u_a(z, t) + \sum_{a < b \in P} \Lambda(a, b, t) \odot [u_a, u_b](z, t)$$

조건	동작
$P = \{ \}$	$v = 0$. control은 움직이지 않는다 — 구조적으로 보장
$ P = 1$	상호작용 항 없음. single 조건이 u_a 를 직접 감독한다
$ P = 2$	교환자 항 하나. Norman-Combosciplex의 경우
$ P \geq 3$	쌍 합은 BCH 2차 절단. 3차 이상은 중첩 bracket으로 확장 가능

4.7 파라미터 수

구성 요소	형태	파라미터
섭동 임베딩	101×64	6.5 K
MLP_h	$(64+32) \rightarrow 256 \rightarrow 256$	90 K
W_U, W_V	$256 \rightarrow 128 \times 16 (\times 2)$	1.05 M
W_β	$256 \rightarrow 128$	33 K
게이트 w, m	$(64+32) \rightarrow 256 \rightarrow 128 (\times 2)$	90 K
합계	$d=128, r=16, d_e=64, d_h=256$	≈ 1.3 M

CellFlow-scDFM의 트랜스포머 백본보다 한 자릿수 작다. 단일 GPU에서 수 분 내 학습된다.

5. 학습

5.1 커플링

control 미니배치와 조건 P의 섭동 미니배치 사이에서 OT 플랜(EMD 또는 Sinkhorn)을 구하고 그 플랜에서 쌍을 뽑는다. 데이터가 unpaired이므로 랜덤 커플링은 분산이 크고 학습 궤적이 굽는다.

5.2 손실

$$z_t = (1-t) z_0 + t z_1, \text{ 목표 속도} = z_1 - z_0$$

$$L_{FM} = E \| v_{\theta}(z_t, t, P) - (z_1 - z_0) \|^2$$

$$L_{dist} = \text{MMD}^2(\text{생성 표본}, \text{실제 표본}) \quad (t=1 \text{ 에서 분포 정합})$$

$$L_{spec} = \sum_a \|A_a\|_F^2 \quad (\text{스펙트럼 폭주 방지})$$

$$L_{gate} = \| \Lambda \|_1 \quad (\text{epistasis 희소성})$$

$$L = L_{FM} + \gamma_d L_{dist} + \gamma_s L_{spec} + \gamma_g L_{gate}$$

L_{gate} 의 근거는 측정값이다. 사전 분석에서 실질적 비가법 조합이 125개 중 18개였다. '상호작용은 희소하다'가 가정이 아니라 **노이즈 바닥 보정 후 측정된 사실**이므로 사전분포로 넣는다.

5.3 학습 스케줄

① single 조건만으로 워밍업하여 u_a 를 안정화한다. single에는 상호작용 항이 구조적으로 없으므로 u_a 가 직접 감독된다. ② 이후 double을 포함해 전체를 학습하며 게이트를 연다. 이 순서가 중요한 이유는 single이 항상 train에 있기 때문이다.

5.4 하이퍼파라미터 초안

batch 512 · Adam $1e-3$ · cosine decay · 100 epochs · rank 16 · d 128

6. 추론과 해석

6.1 적분

$$dz/dt = v_{\theta}(z, t, P), z(0) \sim \text{잠재 control}, t: 0 \rightarrow 1$$

RK4, 20~50 스텝. 유전자 공간 복원은 PCA 역변환 (정확)

6.2 전이 연산자와 스펙트럼

v 가 z 에 대해 affine이므로 흐름 사상은 시간 순서 지수(time-ordered exponential)로 표현된다. 수치 격자에서 이를 추출하면 **섭동 하나가 행렬 하나가 된다**.

$$M(P) = T\text{-exp}(\int_0^1 A_P(t) dt) \approx \prod_i \exp(A_P(t_i) \Delta t)$$

$$A_P(t) = \sum_{a \in P} A_a(t) + \sum_{a < b} \Lambda(a, b, t) \odot [A_b, A_a](t)$$

$M(P)$ 의 고유분해로 어떤 잠재 모드가 증폭·감쇠·회전하는지 읽는다. 사후 해석이 아니라 모델 구조에서 직접 나오는 양이다.

6.3 예측된 epistasis 점수

$$E(a, b) = \| \Lambda(a, b, \cdot) \odot [u_a, u_b] \| \quad (\text{궤적 평균})$$

모델이 **대수적으로 유도한** 상호작용 강도다. 다음 절의 검증에 쓰인다.

7. 선행 연구 대비 차별점

방법	조합 처리 방식	상호작용 항	안 본 쌍 외삽의 근거
CPA	잠재 벡터 덧셈	없음 (가법)	없음
GEARS	유전자 그래프 GNN	암묵적	그래프 이웃
CellFlow (Klein/Theis 2025)	set attention 또는 DeepSets → 조건 벡터	인코더가 암묵 학습	임베딩 유사도
scDFM (2026)	multi-hot + adapter 주입	트랜스포머가 암묵 학습	임베딩 유사도
VGFM (NeurIPS 2025)	해당 없음 (시계열 과제)	—	—
LieCFM (본 제안)	동역학을 대수적으로 합성 (인코딩하지 않는다)	Lie bracket 자유 파라미터 없음	구성 single의 속도장이 결정

기존 방법은 전부 조합을 **인코딩**한다 — attention이든 DeepSets이든 multi-hot이든, 토큰 집합을 하나의 조건 벡터로 압축한 뒤 네트워크에 주입한다. 조합 구조가 인코더 안에 있고, 상호작용은 MLP가 우연히 학습하는 것이다. 본 제안은 **인코딩하지 않고 합성**한다.

왜 flow matching이어야 하는가

이 질문은 리뷰어가 반드시 묻고, 답하지 못하면 치명적이다. 두 개의 답이 있다.

근거	내용
구조적	Lie bracket은 속도장 의 성질이다. δ 를 직접 회귀하는 모델에는 bracket을 취할 대상 자체가 없다. 상호작용 항이 ODE 형식 없이는 존재할 수 없다
데이터	control과 perturbed 세포는 짜지어져 있지 않다 . 세포 단위로 δ 를 회귀할 수 없고, FM + OT가 짝을 만드는 방법이다. 생성 모델이 멋있어서가 아니라 데이터 구조가 요구한다

8. 평가

8.1 목표선 (사전 분석에서 확정)

지표	가법 baseline	넘어야 할 선 (하드 split)	도달 가능 하한
edist_rel	0.191	< 0.163	0.031 (oracle mean)
resid_R2	0	> 0.463	1.0
r_de20	0.9765	포화 — 보고만 하고 판정에 쓰지 않는다	—

평가 하네스, 유전자 disjoint 하드 split 5개, noise floor 보정은 이미 구현되어 있다.

8.2 Ablation (중요도 순)

#	내용	무엇을 분리하는가
1	교환자 항 제거	가법으로 환원. 상호작용 항의 순수 기여
2	교환자 → 자유 MLP $\Delta(e_a, e_b)$	가장 중요. 대수적 형태가 일반화에 기여하는지 분리
3	rank r sweep (4·8·16·32·64)	저랭크 제약의 영향
4	게이트 회소성 on/off	측정 기반 prior의 가치
5	OT 커플링 vs 랜덤 커플링	커플링이 장식인지 부품인지

#	내용	무엇을 분리하는가
6	flow 제거 (δ 직접 회귀)	'왜 flow matching인가'에 대한 선제 방어
7	안정 파라미터화 on/off	구조화 제약의 영향

8.3 반증 가능한 예측

모델의 $E(a,b) = \|\Lambda \odot [u_a, u_b]\|$ 가 사전 분석에서 실측한 **excess ratio**와 상관하는가?
(125개 double, noise floor 보정 완료, 전이 검증 통과. CEBPE 8/11 · MAPK1 5/8 집중)

상관이 나오면 **모델이 대수적으로 유도한 epistasis가 실측 epistasis와 일치한다**는 것이 증명된다. 안 나오면 이론 주장을 축소한다. 이 검증이 없으면 '이론이 장식'이라는 지적을 그대로 받는다. **논문에 반드시 포함한다.**

9. 리스크와 완화

리스크	완화 / 판정
bracket이 약할 수 있다. u_a 가 순수 평행이동($\partial u / \partial z = 0$)이면 bracket이 0이 된다. 사전 분석의 oracle_mean 0.031은 상태 의존성이 작을 수 있음을 시사한다	affine 생성원에서는 $[A_b, A_a]$ 가 일반적으로 0이 아니다. A 성분은 최소 크기 정규화를 걸 수 있다. 구현 2단계에서 만나질 만에 판정되며, 이것이 설계의 생사다
affine 제한이 표현력을 죽인다	사전 분석이 근거다 (gauss_match 0.0066 $\approx$ 노이즈 바닥). 비선형 생성원 + JVP bracket 변형을 부록 실험으로 제시해 프레임워크가 affine에 국한되지 않음을 보인다
발표된 숫자와 프로토콜이 다르다 (scDFM Pearson $\Delta 20$ 0.926 vs 우리 가법 0.980)	논문에서 '지표 포화'를 주장하기 전에 프로토콜을 정렬 해야 한다. 안 하면 첫 문단에서 반박당한다
비가법 표본이 얇다 (18/125, fold당 test에 4~6개)	계층화 보고 + 하드 split. 검정력 분석 병행
분야가 빠르다 (2026 상반기에만 4~5편)	정식 문헌 스윕이 여전히 필요하다. VGFM이 우리 B안과 동일했던 전례가 있다

10. 구현 순서

가장 값싸게 죽일 수 있는 것부터 배치했다. 2단계에서 설계의 생사가 갈린다.

단계	내용	판정 기준
1	잠재 affine FM 코어 (교환자 없음)	가법 baseline 재현 (edist_rel $\approx$ 0.19)
2	교환자 항 추가, on/off 비교	하드 split에서 edist_rel < 0.163 · resid_R2 > 0.463
3	게이트 희소성 + 스펙트럴 정규화	목표선 안정적 통과
4	자유 MLP Δ 대조군	대수적 형태의 기여 분리 (ablation 2)
5	E(a,b) vs excess ratio 검증	이론 검증 그림
6	전체 ablation + Combosciplx ood	논문 표

부록 A. 비선형 생성원으로의 일반화

u_a 가 임의의 신경망일 때도 bracket은 정의된다. Jacobian을 물질화하지 않고 torch.func.jvp 두 번으로 계산한다.

$$[u_a, u_b](z) = J_{\{u_b\}}(z) \cdot u_a(z) - J_{\{u_a\}}(z) \cdot u_b(z)$$

jvp($u_b, z, \text{tangent} = u_a(z)$) 그리고 jvp($u_a, z, \text{tangent} = u_b(z)$)

순전파 비용 약 3배, Jacobian 저장 없음

본 모델은 affine 생성원을 주 설정으로 삼되(사전 분석이 그 충분성을 지지한다), 이 변형으로 프레임워크의 일반성을 보인다.

LieCFM 설계 문서 v1 · 2026-08-11 · 사전 분석 기록은 docs/analysis-report-v1.md 참조