

LT-VAE + LieCFM

구현 파이프라인 확정안 — 데이터 · 마스크 · 실행 순서

PGFM 프로젝트 · 2026-08-12 · HANDOFF-LT-VAE-LieCFM.pdf 의 부록 (Addendum 01)

이 문서의 위치. 재시작 명세서(HANDOFF-LT-VAE-LieCFM.pdf)를 대체하지 않고 덮어쓴다. 충돌하는 항목은 이 문서가 우선한다. 4장의 측정값은 이번에 실제로 재어 확정된 것이므로 재도출할 필요가 없다. 명세서 10절의 미결 항목 중 **GRN / 패스웨이 행렬 M_{GRN}** 은 소스-K커버리지가 여기서 확정된다 (출처 형식 하나만 7장에 남는다).

1. 확정된 설계 변경

명세서 4장 대비 바뀐 세 가지. 나머지 아키텍처(LieCFM 잠재 동역학, 구조적 보장 4개, 2단계 학습, 평가 지표)는 명세서 그대로다.

1.1 마스크 결합식 — tanh 곱셈 게이트

명세서는 $\text{softmax}(QK^T/\sqrt{d_k} + \lambda \cdot M_{GRN})$ 였고 M_{GRN} 은 연결 0 / 미연결 $-\infty$ 였다. 이 형태는 두 가지가 성립하지 않는다. 첫째 $\lambda(-\infty) = -\infty$ 이므로 λ 는 아무 역할도 못 하고 하드 마스크로 남는다. 둘째 softmax 출력은 비음수·합 1 이라 값 집계가 V 의 블록 결합이 되고, **억제(repression)** 는 표현 가능한 함수 공간 안에 없다.

$$\begin{aligned} M_{total} &= \tanh(M_{GRN} + \alpha \cdot M_{learn}) && \in (-1, 1)^{K \times G} \\ A_{enc} &= \text{softmax}_g(Q_{enc} K_{enc}^T / \sqrt{d_k}) && \in \mathbb{R}^{K \times G}, \text{ 행 합 1, 비음수} \\ H_{enc} &= (A_{enc} \odot M_{total}) V_{enc} && \in \mathbb{R}^{K \times d_v} \\ H_{dec} &= (A_{dec} \odot M_{total}^T) V_{dec} && \in \mathbb{R}^{G \times d_v} \end{aligned}$$

역할이 분리된다. **A** 는 "어느 유전자를 보는가"(비음수, 정규화), **M_{total}** 은 "어떤 부호와 세기로 들어오는가". 복잡도는 $O(G \cdot K)$ 로 동일하다.

λ 는 제거한다. 가산 형태에서는 $G=19,264$ 개 키의 개수비를 이기려면 $\lambda \approx 8$ 이 필요했다(패스웨이 50 유전자 기준 $384:1$, $e^{0.762\lambda}=384$). 곱셈 게이트에서는 미연결 유전자가 $M_{total}=0$ 으로 곱해져 죽으므로 개수비와 싸울 일이 없다. λ, γ 대신 H 에 **LayerNorm** 을 둔다.

α 는 학습하지 말고 고정 하이퍼파라미터로 둔다. $\alpha \cdot M_{learn}$ 은 곱만 의미가 있어 둘 다 학습하면 α 가 잉여이고, M_{learn} 에 L1 을 걸면 M_{learn} 을 줄이고 α 를 키우는 회피가 일어난다. **기본값 $\alpha = 1.0$** — 주석된 엣지($M_{GRN}=1$)의 부호를 뒤집으려면 $\alpha|M_{learn}| > 1$ 이 필요한데 $\alpha=0.1$ 이면 $|M_{learn}|=10$ 까지 가야 하고 L1 이 이를 막는다.

M_{learn} 은 **인코더와 디코더가 공유한다**. 억제 엣지에서 디코더는 "패스웨이 활성 $\uparrow \rightarrow$ 유전자 $\downarrow$ ", 인코더는 "그 유전자가 낮게 관측됨 $\rightarrow$ 패스웨이 활성 높음" 이고 둘 다 음수 가중으로 일관된다. 따로 두면 같은 엣지에 모순된 부호를 학습할 수 있다. 스케일만 분리한다.

1.2 prior 소스 — KEGG + 자유 토큰

M_{GRN} 은 KEGG 패스웨이 멤버십에서 만든다. 값은 $\{0, 1\}$ 이진이며 부호가 없다. GRNBoost2 의 importance 도 트리 feature importance 라 항상 비음수이므로, **어느 소스를 쓰든 억제는 전부 M_{learn} 이 배워야 한다**. 이것이 1.1 의 tanh 와 $\alpha \geq 1$ 이 필요한 이유다.

$$K = K_{kegg} (171, \text{prior 있음}) + K_{free} (101, M_{GRN} \text{ 행} = 0)$$

섭동 표적 101개 중 **53개가 유효 KEGG 패스웨이에 속하지 않는다**(4.2절). HOX·FOX·DLX·LHX·ISL2·POU3F2 같은 발생/계보 TF 덩어리이고, KEGG 는 신호전달·대사 DB 라 이 계열을 담지 않는다. 유전자 선택을 바꿔도 해결되지 않으므로, prior 가 비어 있는 자유 토큰을 섭동 표적 수만큼 추가해 모델이 직접 채우게 한다. M_{GRN} 행이 0 이면 수식이 $\tanh(\alpha \cdot M_{learn})$ 이 되어 자동으로 그렇게 동작한다. 외부 데이터도 추가 계산도 필요 없고 누수도 0 이다.

GRNBoost2 는 임계 경로가 아니다. 나중에 **grn_source: both** 로 행을 이어붙여 추가한다(값을 섞지 말 것 — 앞쪽은 주석 토큰, 뒤쪽은 데이터 유래 regulon 토큰으로 의미가 분리된 채 남아야 한다). 누락 53개가 TF 편중이라 regulon 을 받을 가능성이 높지만, 전체 유전자 실행 비용(수 시간~하루)과 누수 규율이 따라온다. 5장의 문제를 먼저 고쳐야 한다.

1.3 유전자 공간 — HVG 3,000 + 표적 101

명세서 8절의 **n_hvg** 기본값 3000 을 유지한다. 섭동 표적 101개를 강제 포함해 **|G| = 3,074**. 마스크 소스와 독립적으로 한 번 고정한다 — 공간이 소스에 따라 달라지면 kegg vs grnboost2 비교가 "다른 prior + 다른 입력"을 동시에 바꿔 ablation 이 무의미해진다.

2. 폐기한 대안 — 마스크 기준 유전자 선택

"KEGG / GRN 을 먼저 돌리고 거기서 나온 유전자를 HVG 3,000 에 우선 포함한다" 는 방향은 측정 결과 잘못된 병목을 겨냥한다.

유전자 공간	G	K	패스웨이 크기(중앙)	표적 101 중 유효 소속	DE 커버리지(프록시)
전체 19,264	19,264	266	72	48	100%
HVG 5000 + 표적	5,062	207	29	47	93.1%
HVG 3000 + 표적 (확정)	3,074	171	22	46	86.3%
KEGG 우선 3000 (폐기)	3,075	217	32	47	65.9%

마스크 지표는 좋아진다(K 171→217, 패스웨이 중앙 22→32). 그러나 **정작 중요한 열은 46→47, 하나 움직인다**. 표적이 패스웨이에 안 잡히는 원인은 HVG 탈락이 아니라 KEGG 주석 자체의 부재이기 때문이다. 대가로 밀려난 유전자 1,345개(평균 raw_var 0.187)와 들어온 유전자 1,346개(평균 0.076)를 맞바꾸며 **DE 유전자 153개를 잃고 33개를 얻는다**. 예측 대상을 빼고 조용한 유전자를 채우는 교환이다.

DE 커버리지 열은 상대 비교로만 읽을 것. |조건평균 - 대조평균| 상위 20 으로 계산한 프록시이며, raw_variance 2000 에서 70.0% 가 나왔다. 명세서 2.3절 기재값은 38.1% 이므로 명세서의 정식 DE 검정을 쓴 것으로 보인다. 같은 프록시를 모든 공간에 일관되게 적용했으므로 **공간 간 순서는 유효하지만 절대값은 명세서 값과 다르다**.

3. 구현 순서 (정정판)

단계	내용	판정 / 비교
0	h5ad 로드 → split 이식·검증 → 평가 하네스(edist_rel, resid_R2, noise floor) → 기준선 재현	split 이 원본과 일치, 명세서 6.2절 표를 재현
1	HVG 3,000 + 표적 101 = 3,074 subset → h5ad 저장 (정규화 없음) + 데이터 로더	4.4절 확인 — 원본이 이미 log1p 정규화본
2	평범한 MLP VAE (Stage 1) + 잠재 Flow Matching (Stage 2, interaction=none)	가법 baseline 수준 재현
3	교환자 항 추가, on/off 및 affine/nonlinear 비교	combinations 에서 목표선 통과 여부 — 설계의 생사
4	KEGG 마스크 K×3,074 조립 → P-CAB / E-RCA 로 인코더·디코더 교체	마스크가 처음 쓰이는 지점
5	Stage 2 동결 vs 미세조정 → free_mlp-flow제거 대조군 → cell-eval Table 1 대조	scDFM 대비 위치 확정

순서를 지킬 것. 명세서 9절의 경고가 그대로 유효하다 — 3단계가 실패하면 인코더를 아무리 정교하게 만들어도 논문의 두 번째 기여가 성립하지 않는다. **지금 만들 인코더는 P-CAB 이 아니라 평범한 MLP VAE 다.** 1.2절에서 확정한 KEGG 마스크는 4단계용 준비물이고 그때까지 쓰이지 않는다.

용어 하나. 5단계 산출은 "세포 생성" 이 아니라 **"대조군 세포를 섭동 상태로 수송"** 이다. 대조군 세포를 인코딩해 z_0 을 얻고, 속도장 v_θ 를 RK4 로 적분해 z_1 을 만들고, 디코딩한다. 무에서 만드는 것이 아니라 분포를 옮기는 것이고, 대조군과 섭동 세포가 짝지어져 있지 않다는 문제는 조건별 UOT 커플링이 처리한다.

4. 측정으로 확정된 사실 — 재도출 불필요

4.1 데이터 무결성 (assets/norman.npz ↔ 명세서)

항목	측정값	명세서
condition 구성	control 1 + single 101 + double 125 = 227	일치
두 single 을 모두 보유한 double	125 / 125	일치
double 조건당 세포 수	46 ~ 1,005 (중앙 248)	일치
control 세포	7,275	일치
섭동 표적 $\in$ 19,264 유전자	101 / 101	—
섭동 표적 $\in$ modeled 3,074	101 / 101 (force_include_targets 작동)	—
top-3000 raw_variance $\cap$ npz gene_idx	2,999 / 3,000 (재현 확인)	—

4.2 KEGG 커버리지

출처: KEGG REST (rest.kegg.jp) 2026-08-12 수신. assets/kegg/ 에 원본 3종 보관 — pathway_list 372행, pathway_gene 39,574행, gene_list 24,252행.

측정	값	함의
KEGG 유전자 → Norman 심볼 매칭	8,442 / 19,264 = 43.8%	alias 폴백 포함 (primary 만: 8,383)
섭동 표적 101 중 KEGG 소속	56 / 101 = 55.4%	질병·크기 필터 전
섭동 표적 101 중 유효 패스웨이 소속	48 / 101 (전체 공간)	질병 제외 + 크기 10~300 필터 후
필터 후 K ($ G =3,074$)	171	패스웨이 크기 중앙 22, 평균 26.8
M_GRN 밀도 ($171 \times 3,074$)	0.87%	매우 희박 — α 가 작으면 주석에 갇힌다
행 간 Jaccard	중앙 0.000 · 평균 0.037 · >0.3 인 쌍 1.3%	중복 우려는 기각됨
HVG 3,000 중 KEGG 소속 비율	54.8% (전체 유전자에서는 43.8%)	KEGG 유전자는 이미 고분산 쪽 편중

KEGG 미소속 45개 (발생/계보 TF 편중): ARRDC3, ATL1, CBFA2T3, CELF2, CITED1, CNN1, CNM4, CSRP1, DLX2, FOXA1, FOXF1, FOXL2, GLB1L2, HOXA13, HOXB9, HOXC13, IER5L, IGDCC3, IKZF3, ISL2, KLF1, LHX1, MAP4K5, MAP7D1, MIDN, NIT1, OSR2, POU3F2, PRDM1, PRTG, PTPN12, PTPN9, RHOF2, RREB1, SAMD1, SET, STIL, TBX2, TSC22D1, UBASH3A, UBASH3B, ZBTB1, ZBTB10, ZBTB25, ZNF318

질병 패스웨이(hsa05xxx) 제외 필터가 표적 8개를 희생시킨다(56→48). **drop_disease_pathways** 를 축으로 열어두고 나중에 재볼 것. 거대 통합 패스웨이(hsa01100 등)는 크기 300 상한에서 걸리지며, 이것이 Jaccard 중복이 낮은 이유다.

4.3 평가 공간 포함 검증 — HVG 3,000 을 쓸 수 있는 근거

명세서 6.3절의 평가 공간은 "HVG 1000 on adata_test" 다. 모델 입력 공간이 3,074 로 좁을 때 평가 대상 유전자가 그 밖에 있으면 예측 자체가 불가능하다. 10개 fold 전부에서 확인했다.

split	평가공간 1,000개 중 HVG3000+표적에 포함	HVG5000+표적
additive fold 0~4	1000 / 1000 (전 fold 100%)	1000 / 1000
combinations fold 0,1,3,4	1000 / 1000	1000 / 1000
combinations fold 2	999 / 1000 (99.9%)	1000 / 1000

4.4 정규화 상태 — 다시 하면 안 된다

data/norman/norman.h5ad 의 **X** 는 이미 **log1p** 정규화본이다. **csr_matrix**, 값 범위 0.305 ~ 6.405, 정수 아님, **layers** 비어 있음, raw count 레이어 없음. 원본 count 는 보존돼 있지 않아 되돌릴 수도 없다. 전처리에서 **normalize_total / log1p** 를 다시 적용하면 **이중 정규화**가 된다. 1단계는 subset 만 한다.

참고로 **hvg_criterion** 의 **raw_variance** 는 "정규화 전 데이터" 가 아니라 이 log1p 데이터 위에서의 **단순 분산**을 뜻한다(scanpy 의 dispersion 기준과 대비되는 이름).

4.5 split 구조

파일	fold	내용
assets/splits_additive.pkl	5	키 {train, test} · fold0 = train 88 / test 37
assets/splits_combinations.pkl	5	키 {test, test_doubles, held_out_singles, held_out_genes, train, train_doubles, train_singles, missing_singles} · fold0 = test 38 (double 15 + held-out single 23) / train 188

5. 기존 GRN 스크립트의 문제 — 재사용 전 수정 필요

src/utls/generate_grn_from_data_pipeline.py 와 **build_combosciplex_processed_cache.py** 검토 결과. GRNBoost2 를 도입할 때(1.2절, grn_source: both) 반드시 먼저 처리한다.

심각도	문제	수정
치명	산출물이 vocab 정렬 N×N 유전자-유전자 행렬. P-CAB 이 필요한 것은 K×G	TF 를 패스웨이 토큰으로 삼아 $M[k,g] = \text{norm_importance}(\text{TF}_k \rightarrow \text{gene}_g)$
치명	combinations split 누수. select_grn_input_adata() 가 single/control 을 무조건 전량 보존하는데, combinations 에서는 held-out single 23개가 test 다. --split_method 를 바꿔도 이 분기는 그대로다	조건 기반으로 통일: 모든 split_method × 모든 fold 의 test 합집합을 제외
차단	의존 코드 전부 삭제됨 — src.data_process.data, src.utls._preprocessing, process_vocab, src/tokenizer/*.json, data/scDFM/ 경로 (실제는 data/norman/)	vocab/tokenizer 계열은 되살릴 필요 없음. 정렬 기준은 adata.var_names 하나
재현성	grnboost2() 에 seed 미전달 — 재실행마다 다른 GRN	seed 고정 + 산출물을 assets/ 아티팩트로 버전 관리
운영	유전자 축이 HVG 선택에 종속 — n_hvg ablation 마다 재실행	전체 유전자로 1회 실행 → 옛지 리스트에서 열 슬라이싱
소소	정규화 로직이 두 곳에 복제(CSV ↔ .pt 어긋남 위험) · TF 리스트 런타임 GitHub 다운로드 · p99 clip 으로 상위 1% 동률 · self-loop 규약이 G×G 전용	함수로 추출 · assets/ 에 커밋 · 순위 기반을 축으로 · mask_self_loop 설정

combosciplex 관련 코드 전체는 명세서 2.1절이 "조합 벤치마크로 쓸 수 없다" 고 결론 낸 데이터에 대한 것이다. "다른 modality 분포 이동" 프레임링을 유지한다면 남기되 우선순위는 뒤로. PubChem/rdkit 의존성도 여기서만 필요하다.

6. 설정 축 — 명세서 8절에 추가

```
# data
n_hvg          : 3000          # None = 전체
hvg_criterion  : raw_variance | dispersion
force_include_targets : true
grn_source     : kegg | grnboost2 | both
kegg_gmt       : assets/kegg/  # 또는 MSigDB GMT (심볼 기반, 권장)
pathway_min_genes : 10
pathway_max_genes : 300
drop_disease_pathways : true
n_free_tokens   : 101         # M_GRN 행 = 0 인 자유 토큰

# model — 마스크
mask_combine    : gate | logit_bias  # 곱셈 게이트(기본) vs 가산(대조군)
mask_mode       : hybrid | grn_only | learned_only
mask_alpha      : 1.0              # 고정. 학습시키지 말 것
mask_signed     : true | false      # false = sigmoid, 억제 기여 분리용 대조군
mask_share_enc_dec : true
mask_l1         : M_learn L1 계수
mask_self_loop  : true | false
```

반드시 넣어야 할 대조군. 명세서 8절의 두 가지(interaction=free_mlp, flow 제거)에 더해 **mask_signed=false** 를 추가한다. 부호 도입이 1.1 변경의 목적이므로 그 기여를 숫자 하나로 분리해 보여야 한다. 또한 **mask_mode** 의 **grn_only / learned_only** 는 선택이 아니라 필수다 — "자유 행렬이 KEGG 를 그냥 재학습한 것 아니냐" 는 질문에 답하는 유일한 수단이다.

7. 미결 사항

항목	상태
KEGG 출처 확정	REST 수신본으로 측정했다. 재현성만 보면 MSigDB GMT (심볼 기반, 릴리스 고정) 가 낫다. Entrez→심볼 매핑 단계가 통째로 빠지고 버전이 번호로 고정된다. MSigDB 로그인도 필요해 직접 받아야 한다
K_free = 101 이 적당한가	섭동 표적 수에 맞춘 초기값. n_free_tokens 를 축으로 두고 실측할 것
DE 커버리지 정식 정의	명세서 2.3절의 38.1% 를 재현하는 DE 검정 정의를 확정해야 2장 표의 절대값이 의미를 갖는다
Table 1 의 L2 · Pearson Δ_0 정의	명세서 10절에서 이월. cell-eval 에 없음
cell-eval 재현의 시드 변동	명세서 10절에서 이월. 단일 시드 1회만 측정됨
패스웨이 VAE 선행 연구 포지셔닝	VEGA / expiMap / pmVAE 는 마스크된 선형 디코더 + 고정 주석. 우리는 같은 prior 소스에 세포별 어텐션 + 부호 학습 보장이라 기여 귀속이 깨끗하다는 점을 한 문단으로

부속 자료: docs/HANDOFF-LT-VAE-LieCFM.pdf (재시작 명세서, 이 문서의 상위), docs/LieCFM-method.pdf (Method 초안), assets/kegg/ (KEGG REST 원본 3종), assets/splits_*.pkl (검증된 split), assets/norman.npz (전처리본 — Z / W / pc_mean 은 폐기된 PCA 경로 산출물이므로 genes / perts / conds / mean / var / ncell 만 재사용).